XVII Jornadas de Ingeniería Telemática
JITEL 2025
Universidad de Extremadura

Actas de las XVII Jornadas de Ingeniería Telemática (JITEL 2025), Cáceres (España), 12-14 de noviembre de 2025.

Herramienta de Preprocesamiento de Tráfico IoMT para Generación Configurable de *Datasets*

Olga León, Isabel V. Martin-Faus, Josep Pegueroles, Jordi Doménech
Departamento de Ingeniería Telemática,
Universitat Politècnica de Catalunya (UPC),
c. Jordi Girona 1-3, 08034, Barcelona, Spain.
{olga.leon, isabel.martin-faus, josep.pegueroles, jordi.domenech.fons}@upc.edu

La incorporación de dispositivos IoT médicos (*IoMT, Internet of Medical Things*) está transformando el sector sanitario, mejorando la monitorización de pacientes y optimizando la gestión hospitalaria. También está incrementando la superficie de ataque, exponiendo datos sensibles y poniendo en riesgo la seguridad del paciente. Entre los métodos para proteger los entornos IoMT destacan los sistemas de detección y prevención de intrusiones (IDPS) basados en Inteligencia Artificial (IA). Estos requieren de bases de datos de calidad para entrenar los modelos de aprendizaje automático y lograr una eficiencia elevada. En este trabajo presentamos una herramienta que, a partir de tráfico de red IoMT y la extracción configurable de atributos relevantes, facilita la generación de *datasets* y, en particular, obtener *datasets* específicos que permitan entrenar el IDPS según el modelo de IA usado. La herramienta incluye hasta 103 características distintas de tráfico de red, esto es el número más elevado tenido en cuenta hasta la fecha. La flexibilidad en la selección de parámetros mejora la calidad de los datos utilizados e incrementará la eficiencia de los IDPS. La herramienta ha sido validada dentro del *testbed* (MIoTTA) desarrollado en la UPC para obtener tráfico de red según el comportamiento de una habitación hospitalaria con sistema de telemetría. Su diseño modular ofrece una solución versátil para investigadores y profesionales que buscan generar *datasets* robustos y realistas para la detección proactiva de amenazas en entornos médicos conectados.

***Palabras Clave*—IoMT, Sistemas de Detección de Intrusión, Datasets, Testbed, Aprendizaje Automático.**

I. INTRODUCCIÓN

La Internet de las Cosas (IoT, *Internet of Things*) está transformando el sector sanitario, permitiendo una atención médica más eficiente, personalizada y en tiempo real. Los dispositivos médicos conectados (IoMT, *Internet of Medical Things*), que tanto monitorizan constantes vitales como automatizan la gestión hospitalaria, mejoran significativamente la calidad de los servicios de salud [1]. Sin embargo, los avances en digitalización también plantean importantes desafíos de ciberseguridad exponiendo datos sensibles a vulnerabilidades y amenazas, que en ocasiones incluso pueden comprometer la integridad física del paciente [2].

La protección de redes IoMT frente a ciberataques es especialmente crítica en dispositivos activos (por ejemplo, bombas de infusión, ventiladores mecánicos, desfibriladores implantables y marcapasos), cuyas acciones automatizadas pueden afectar severamente la salud de los pacientes [3]. Los Sistemas de Detección y Prevención de Intrusiones (IDPS, *Intrusion Detection and Prevention System*) son una buena solución para identificar las amenazas y ofrecer una respuesta rápida ante ataques [4].

Entre las tecnologías usadas para el diseño de IDPS en IoMT, la inteligencia artificial (IA) es una de las más prometedoras [5], [6]. La IA permite analizar grandes volúmenes de datos en tiempo real, identificar patrones anómalos y predecir amenazas con precisión y rapidez. Los modelos de aprendizaje automático (ML, *Machine Learning*) son los más explorados actualmente para reducir falsos positivos y optimizar la respuesta en sistemas críticos de salud [7].

Es conocido que la IA requiere de *datasets* amplios, representativos y fiables para su correcto entrenamiento, validación y prueba. La calidad de los datos en estos tres aspectos es crucial e influye directamente en la precisión y capacidad de generalización del modelo. En el ámbito de la ciberseguridad, además, la adquisición de datos debe incluir ataques lo más diversos posibles, así como comportamientos normales para garantizar que el sistema pueda identificar y clasificar amenazas con alta fiabilidad.

Este trabajo tiene como objetivo proporcionar una her-

This work is licensed under a Creative Commons 4.0 International License (CC BY-NC-ND 4.0)

ramienta software para la generación de *datasets* (en formatos CSV y *nPrint*), a partir de ficheros PCAP de capturas de tráfico de red.

El resto del artículo está organizado de la siguiente manera: La Sección II analiza trabajos similares en *datasets* existentes, y destaca sus limitaciones. La Sección III introduce brevemente el *pipeline* de preprocesado y lo ubica en el proceso global de funcionamiento de un IDPS. Las Secciones IV y V, respectivamente, describen la herramienta en sí con sus funcionalidades y muestran un caso de uso en el *testbed* desarrollado por el equipo investigador. Finalmente, la Sección VI presenta conclusiones y líneas futuras.

II. TRABAJOS RELACIONADOS

En el ámbito de la ciberseguridad se conocen distintos trabajos que emplean herramientas de preprocesamiento de tráfico de red, en particular para entornos IoT e IoMT, con el objetivo de entrenar modelos de detección de intrusiones basados en inteligencia artificial. Las herramientas suelen convertir archivos de captura de paquetes de red (PCAP) en representaciones estructuradas que contienen atributos específicos sobre el tráfico observado. No obstante, la mayoría de las herramientas existentes presentan limitaciones importantes en términos de configurabilidad y granularidad. Además, la mayoría de ellas no están disponibles públicamente. Esto restringe su aplicabilidad a experimentos personalizados o necesidades específicas para la investigación. Los detalles de estas herramientas se describen en la Tabla I.

Por ejemplo, los *datasets* CICIoT2023 [12] y CICIoMT2024 [13], desarrollados por el Canadian Institute for Cybersecurity (CIC), utilizan herramientas internas para la extracción de atributos de red. Estas herramientas, las cuales están disponibles parcialmente de forma pública, extraen atributos a través de ventanas de paquetes y flujos. El CIC, además, tiene desarrollada una herramienta interna llamada CICFlowMeter [8] para la extracción de características. Aunque esta herramienta sí que está disponible públicamente, solo opera exclusivamente a nivel de flujo, con un conjunto predefinido de atributos, sin ofrecer al usuario la posibilidad de configurar el tipo de extracción o la selección de atributos.

El *dataset* IoT-Healthcare [14] también utiliza una herramienta propia, disponible públicamente, para convertir archivos PCAP a CSV. Los archivos finales (en formato CSV) incorporan únicamente 50 atributos, y éstos sólo se extraen a través de paquetes individuales.

Una situación similar se observa en otros *datasets* como IoMT-TrafficData [15] y WUSTL-EHMS [16]. En éstos las herramientas de preprocesamiento son cerradas, poco documentadas o limitadas a un número muy reducido de características. Además, el tipo de extracción de los atributos es limitado a flujos y paquetes, o a flujos y datos biométricos, respectivamente.

En contraste, la herramienta propuesta en este estudio ofrece una solución integral y altamente configurable. Es capaz de extraer atributos de red a nivel de paquete, flujo, ventana de paquetes o mediante la combinación de todos estos, permitiendo generar hasta 103 atributos distintos, todos configurables por el usuario. La herramienta también es capaz de extraer el contenido de los paquetes bit a bit, mediante el estándar *nPrint* [17]. Esta flexibilidad convierte nuestra propuesta en una herramienta única y novedosa de preprocesamiento de tráfico de red, especialmente orientada a la generación de *datasets* personalizados para la detección de amenazas en entornos IoMT.

III. PIPELINE PARA LA RECOLECCIÓN Y PROCESADO DE DATOS

Típicamente, en escenarios como el que nos ocupa, la recolección y procesado de datos sigue una *pipeline* estructurada, ilustrada en la Fig. 1, que permite capturar, procesar y almacenar el tráfico de red generado por los dispositivos IoMT en distintos formatos. La captura inicial de datos se realiza en formato PCAP, que posteriormente puede ser convertido a CSV o a *nPrint* [17] para entrenar y evaluar modelos IA de detección de ciberataques. Estos modelos nos permiten detectar comportamientos de red anómalos de forma precisa y automatizada, evitando así filtraciones de datos médicos o ataques que puedan afectar a la salud de los pacientes.

El objetivo principal de esta *pipeline* es proporcionar una metodología para desarrollar *datasets* configurables y flexibles, que permitan evaluar múltiples enfoques de modelado en el ámbito de la ciberseguridad en entornos médicos. Gracias a la herramienta de preprocesado propuesta, los investigadores podrán generar datos con distintas configuraciones para poder entrenar algoritmos de inteligencia artificial y estudiar su comportamiento. En esta *pipeline* también describimos el *testbed* MIoTTA-UPC que estamos desarrollando en la UPC como parte de la recolección de datos de dispositivos IoMT. Este *testbed* se describe en más detalle en la sección V.

A. Recolección de datos

El tráfico de red generado en el *testbed* se captura utilizando *Wireshark* [18] y se almacena en ficheros PCAP. Esta captura incluye las comunicaciones entre los dispositivos IoMT físicos y simulados, y el *gateway*, permitiendo la observación de patrones de tráfico bajo condiciones normales y de ataque.

Las capturas pueden realizarse de forma continua o en intervalos de tiempo predefinidos, dependiendo del experimento en cuestión. Se registran los paquetes que circulan por la red, pertenecientes a de MQTT y CoAP, así como otros protocolos utilizados en la comunicación (p. ej., ARP, TCP, etc.).

B. Preprocesamiento de los datos

Una vez capturado el tráfico en formato PCAP, se utiliza la herramienta configurable de preprocesado, descrita en detalle en la sección IV, para convertir los datos en formatos más adecuados para el entrenamiento de modelos de inteligencia artificial; como son CSV y *nPrint*.

El formato CSV se obtiene extrayendo estadísticas del tráfico de red a partir de la captura PCAP, y bajo tres

This work is licensed under a Creative Commons 4.0 International License (CC BY-NC-ND 4.0)

Tabla I: Tabla comparativa de herramientas de preprocesado en entornos IoMT conocidos.

Herramienta/Dataset	Año	Tipo de Extracción	Formato de Datos	Configurable	Nº de atributos	Pública	Referencia
CICFlowMeter	2016	Flujos	CSV	No	76	Sí	[8]
WUSTL-EHMS	2020	Flujos	CSV	No	34	No	-
IoT-Healthcare	2021	Paquetes	CSV	No	50	Sí	[9]
CICIoT2023	2023	Flujos, Ventanas	CSV	No	47	Sí	[10]
CICIoMT2024	2024	Flujos, Ventanas	CSV	No	45	No	-
IoMT-TrafficData	2024	Flujos, Paquetes	CSV	No	64	No	-
Herramienta propuesta	**2025**	**Flujos, Paquetes, Ventanas**	**CSV, nPrint**	**Sí**	**Hasta 103**	**Sí**	[11]

enfoques diferentes: análisis por paquetes, análisis por flujos y análisis por ventana de paquetes. Este enfoque flexible permite analizar el tráfico a distintos niveles de granularidad, facilitando la extracción de patrones relevantes para la detección de ciberataques.

El segundo formato en el que se convierten los datos es *nPrint* [17], el cual proporciona una representación binaria de los paquetes capturados. En este caso, el script transforma directamente el contenido de los campos de cada paquete en una secuencia de bits. Esto permite que modelos de aprendizaje profundo (*deep learning*) puedan analizar la estructura de los paquetes sin la necesidad de aplicar ingeniería de características de red de forma manual.

C. Entrenamiento y evaluación de algoritmos de detección

La última fase de la *pipeline* consiste en entrenar y evaluar los algoritmos de detección de intrusiones basados en IA, utilizando los datos capturados y procesados en los pasos anteriores. Asimismo, se pueden utilizar distintos tipos de algoritmos, como por ejemplo árboles de decisiones (*Decision Tree*, *Random Forest* o *XGBoost*), y redes neuronales (*FeedForward Neural Networks* o redes neuronales basadas en algoritmos de *Time Series Classification*), entre otros. Se ha podido comprobar el buen rendimiento de estos algoritmos en estudios anteriores, dando resultados excelentes en la detección de ciberataques en redes IoMT [19].

IV. HERRAMIENTA PROPUESTA

En esta sección presentamos la herramienta propuesta: una herramienta flexible y extensible desarrollada para convertir archivos de red en formato PCAP, a representaciones numéricas en formato CSV o *nPrint*. Está diseñada específicamente para algoritmos de detección de intrusiones basados en inteligencia artificial, con un enfoque especial a redes de dispositivos IoMT.

A. Descripción de la herramienta

La herramienta se ha diseñado con el objetivo de ofrecer un preprocesamiento altamente configurable, permitiendo a los investigadores o desarrolladores seleccionar tanto el nivel de granularidad de los datos, como el conjunto exacto de atributos a extraer. Asimismo, la herramienta desarrollada permite obtener un conjunto de ficheros en formato CSV y *nPrint* a partir de capturas de red en formato PCAP. Entre las principales funcionalidades de la herramienta, destacan:

- Conversión de tráfico PCAP a CSV estructurado con múltiples estadísticas.
- Soporte para tres niveles de agregación:
  - Nivel de paquete: se extraen los atributos de cada paquete de manera individual. De este modo, cada paquete de la captura PCAP da lugar a una línea del fichero CSV.
  - Nivel de flujo: se identifican los paquetes asociados a un mismo flujo (i.e., aquellos que contienen las mismas direcciones IP y puertos, tanto origen como destino), y se extraen los atributos por flujo. En este caso, el número de líneas del fichero de salida dependerá del número de flujos identificados en la captura.
  - Nivel de ventana: los paquetes de la captura PCAP se agrupan en ventanas de N paquetes, y se extraen los atributos promediando los valores de todos los paquetes de la ventana, dando lugar a una línea del fichero de salida por cada N paquetes a la entrada.
  - Nivel combinado (flujos y ventanas): se agrupan los paquetes de la captura en ventanas de N paquetes, se identifican los flujos dentro de dicha ventana y se extraen los atributos por flujo. De esta manera, los atributos extraídos serán una adición de los atributos a nivel de flujo y a nivel de ventana.
- Exportación alternativa a formato *nPrint*, donde se extrae la información bit a bit de cada uno de los paquetes de red capturados.

En la Fig. 2 podemos ver el diagrama de flujo de la herramienta, donde la entrada es un fichero PCAP. En cuanto a la salida, esta puede ser un fichero CSV con los atributos de red especificados por el usuario, o un fichero cuyo formato sea *nPrint*.

B. Extracción de atributos de tráfico de red

La conversión de PCAP a CSV se realiza mediante la extracción de atributos estadísticos y estructurales de cada paquete, flujo o ventana. Para hacerlo, se utiliza la herramienta *tshark* [20]: *tshark* nos ayuda a extraer las estadísticas básicas de los paquetes, para, posteriormente, poder calcular los atributos específicos del tráfico de red. Estos atributos permiten representar de forma numérica el comportamiento de la red, facilitando su procesamiento por modelos de inteligencia artificial. La herramienta ofrece hasta 103 atributos de red distintos, que pueden ser activados o desactivados por el usuario, agrupados en las

This work is licensed under a Creative Commons 4.0 International License (CC BY-NC-ND 4.0)

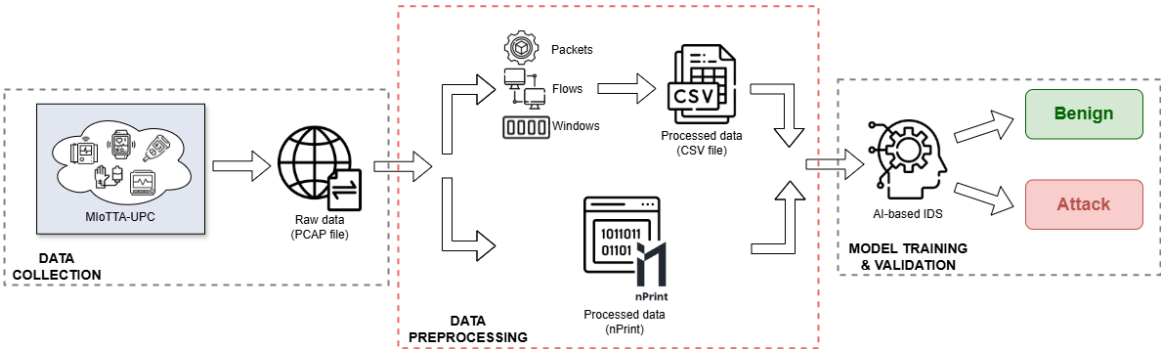


Fig. 1: *Pipeline* para la recolección y preprocesado de datos del *testbed* MIoTTA-UPC.

categorías de paquete (25 atributos), flujo (42 atributos) o ventana (36 atributos). Estos atributos y su significado se presentan en la Tabla II del Apéndice.

Además de la flexibilidad de la herramienta, cabe destacar que, a diferencia de otras herramientas existentes como CICFlowMeter [8] o IoMT-TrafficData [15], que únicamente extraen un conjunto reducido de características básicas de flujos o flujos y paquetes, respectivamente; nuestra herramienta proporciona una extracción mucho más exhaustiva y flexible de características de red, lo que la convierte en una solución más completa para entornos de análisis avanzados y detección de intrusiones. Asimismo, la herramienta también ha sido diseñada para permitir añadir nuevos atributos en el futuro mediante una arquitectura modular.

C. Soporte para formato nPrint

Además de la conversión a CSV con los atributos de tráfico de red, la herramienta ofrece la opción de transformar los paquetes PCAP al formato *nPrint* [17], una representación binaria de paquetes diseñada para alimentar directamente algoritmos de deep learning. En este modo, los paquetes son trasformados en vectores de bits mediante un proceso configurable:

- Posibilidad de truncar a los primeros N bytes del paquete.
- Inclusión de encabezados específicos, como pueden ser Ethernet, IP, TCP, UDP, ICMP y ARP.
- Opciones para mantener o eliminar la carga útil (payload).
- Formato de salida compatible con frameworks como PyTorch y TensorFlow.

Esta funcionalidad es especialmente útil en modelos de aprendizaje profundo, tales como modelos basados en redes neuronales convolucionales (CNN) o modelos híbridos, que analizan directamente la estructura binaria del tráfico. Además, la flexibilidad de la herramienta, que permite al usuario seleccionar de forma personalizada los atributos a emplear, facilita una reducción significativa del tamaño de los conjuntos de datos utilizados en estos modelos. En particular, el formato original de *nPrint* genera representaciones altamente detalladas y voluminosas, que pueden resultar difíciles de procesar en entornos con recursos computacionales limitados. Con la herramienta propuesta, el usuario puede configurar de manera eficiente los atributos extraídos, seleccionando únicamente aquellos más relevantes para su caso de estudio, lo que mejora la escalabilidad y manejabilidad del proceso de análisis.

V. USO DE LA HERRAMIENTA EN UN ENTORNO IOMT

En esta sección se describe el entorno de validación (*testbed*) empleado para comprobar la utilidad práctica de la herramienta desarrollada, centrado en un contexto realista del Internet de las Cosas Médicas (IoMT). Asimismo, se explica su uso, destacando las funcionalidades clave mediante ejemplos gráficos extraídos de su ejecución.

A. Entorno experimental: MIoTTA-UPC

La arquitectura del *testbed* MIoTTA-UPC [21], [22] representada en la Fig. 3, está diseñada para replicar un entorno realista de dispositivos IoMT en un contexto hospitalario, simulando una habitación de hospital, donde uno o más pacientes están conectados a distintos dispositivos médicos. Esta arquitectura combina dispositivos físicos reales con dispositivos simulados para garantizar la diversidad y realismo de los datos obtenidos. Esto permite el estudio de ciberataques en un entorno configurable, mejorando así la robustez de los algoritmos de detección de intrusiones basados en inteligencia artificial.

1) Infraestructura de Red y Flujo de Datos: La arquitectura del *testbed* MIoTTA-UPC se organiza en diferentes capas funcionales que simulan el flujo de datos en un entorno hospitalario:

- Dispositivos IoMT (físicos y simulados) en la habitación del hospital, los cuales generan datos biomédicos y los envían al *gateway* utilizando protocolos ligeros como MQTT o CoAP.
- *Gateway* que actúa como intermediario en la comunicación; se encarga de recibir los datos de los sensores y reenviarlos al *Router/Access Point (AP)* utilizando comunicación WiFi (*IP-based*).
- *Router/AP* que gestiona la conectividad de la red hospitalaria, asegurando la transmisión de los datos hacia el servidor *proxy*.
- Servidor *Proxy* que permite que el personal sanitario acceda en tiempo real a la información del paciente sin comprometer la seguridad del servidor central.

This work is licensed under a Creative Commons 4.0 International License (CC BY-NC-ND 4.0)

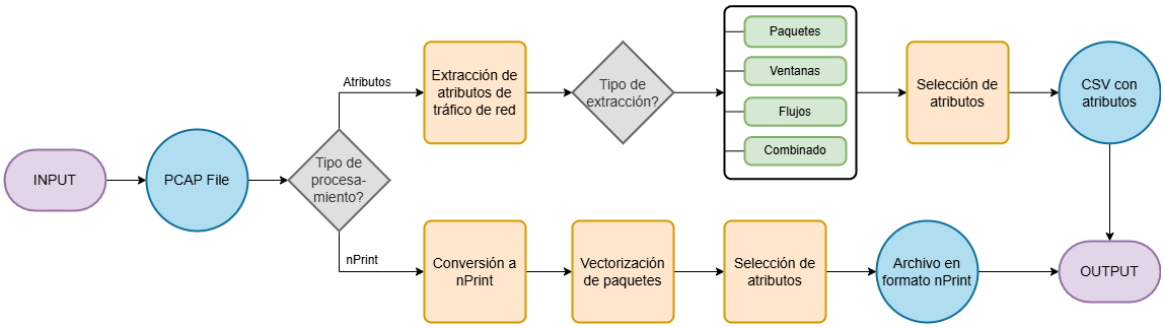


Fig. 2: Diagrama de flujo de la herramienta propuesta.

- Servidor del Hospital que almacena la información médica relevante para el análisis centralizado de los datos.

Estas capas funcionales proporcionan un entorno controlado, flexible y realista para la evaluación de diferentes estrategias de detección de ciberataques.

2) Dispositivos IoMT y sensores: El *testbed* incluye una serie de sensores médicos reales, los cuales son:

- Electrocardiógrafos (ECG) AD8232: utilizados para la monitorización de señales cardíacas.
- Pulsioxímetros MAX30100: encargados de medir la saturación de oxígeno en sangre (SpO2) y la frecuencia cardíaca.
- Sensores de Pulso Aihasd: utilizados para monitorizar la frecuencia cardíaca y la forma de onda del pulso.

Estos sensores médicos están conectados a dispositivos embebidos (i. e., Arduino Uno y Raspberry Pi) que actúan como unidades de preprocesamiento y transmisión de datos. Estos dispositivos se emplean principalmente para la adquisición y preprocesamiento de datos de los sensores, y utilizan los protocolos ligeros de red MQTT y/o CoAP para comunicarse.

Además, para garantizar la diversidad y representatividad del tráfico de red, el *testbed* también integra dispositivos médicos simulados mediante la herramienta IoT-Flock [23] y Dockers propios. Estas herramientas permiten generar tráfico simulado de dispositivos IoT y IoMT de manera realista. Esto aporta distintas ventajas al *testbed*, aumentando la diversidad de dispositivos del *dataset*, más allá de los sensores físicos desplegados. Esta combinación favorece que la base de datos resultante represente una amplia variedad de escenarios, mejorando así la robustez de los algoritmos de detección de ciberataques. Los dispositivos simulados mediante IoT-Flock y Dockers son los siguientes:

- Sensor de flujo nasal: utilizado para el seguimiento de la respiración del paciente.
- Bomba de infusión: simula la administración de medicamentos intravenosos.
- Monitor de presión arterial: utilizado para la detección de hipertensión o hipotensión.
- Sistema de monitoreo de glucosa: encargado de la supervisión de los niveles de azúcar en pacientes diabéticos.
- Termómetro: mide la temperatura corporal de los pacientes.
- Anillo monitor de sueño: realiza un seguimiento de la calidad del sueño y los signos vitales durante el sueño.
- Detector de caídas: detecta caídas repentinas mediante sensores de movimiento.
- Sensor de monitor de sueño para bebés: rastrea la postura del bebé para detectar posiciones peligrosas para dormir.

3) Almacenamiento y procesado de los datos: Los datos capturados se almacenan y procesan en una infraestructura basada en un servidor, que cumple las siguientes funciones:

- Captura de tráfico en tiempo real mediante herramientas como *tcpdump* y *Wireshark*, generando archivos PCAP con registros detallados de la comunicación en la red.
- Preprocesamiento y etiquetado de los datos, facilitando la estructuración del *dataset* para su aplicación en algoritmos de aprendizaje automático. Esta función convierte los datos sin procesar (PCAP) a datos procesados (CSV) con características y estadísticas relevantes del tráfico de red. La herramienta utilizada para el preprocesado se detalla en la sección IV.

4) Modelo de Amenaza (Atacante Interno): En el *testbed*, se asume un modelo de atacante interno, es decir, un adversario que ya ha realizado el acceso inicial a la red. Este atacante, simulado utilizando un dispositivo *Kali Linux*, tiene la capacidad de interferir en las comunicaciones IoMT, interceptando o alterando datos médicos transmitidos, o hasta interrumpiendo el acceso en tiempo real a los datos del paciente. La detección de estos ataques es de suma importancia en entornos médicos, ya que su correcta ejecución puede poner en peligro la integridad física de los pacientes que estén ingresados en una red clínica integrada.

Debido a su naturaleza, los dispositivos IoMT son particularmente vulnerables a numerosos ataques de ciberseguridad, como brechas de datos, accesos no autorizados o denegaciones de servicio. Las principales amenazas que afectan a los dispositivos IoMT basados en los protocolos MQTT y CoAP y que se utilizan en el *testbed*, se detallan a continuación. Dichas amenazas se agrupan en 6 categorías,

This work is licensed under a Creative Commons 4.0 International License (CC BY-NC-ND 4.0)

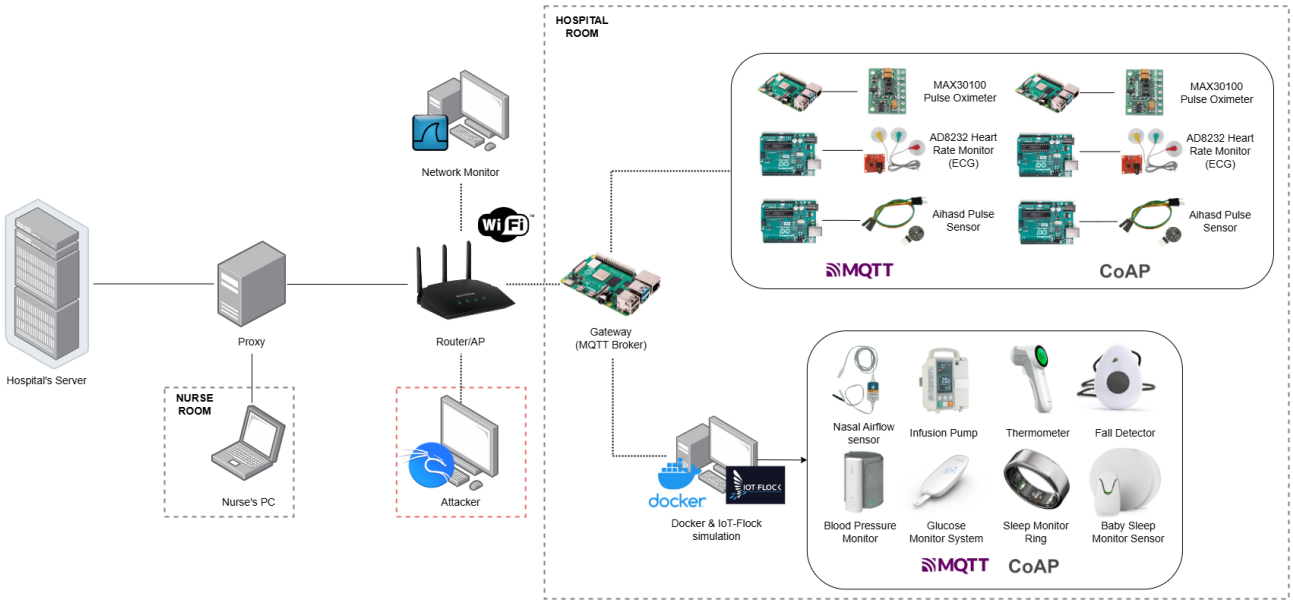


Fig. 3: Arquitectura del *testbed* MIoTTA-UPC.

siguiendo la taxonomía propuesta en trabajos previos [14], [24], [16], [13]:

- Ataques de Denegación de Servicio (DoS): Envío masivo de mensajes con el objetivo de consumir los recursos del broker MQTT o el servidor CoAP, de modo que no pueda ofrecer servicio a usuarios legítimos. Existen numerosas subcategorías según el modo en como se implemente el ataque y el protocolo, como pueden ser SYN flooding, Publish flooding, Connect flooding, etc. Una de las herramientas más populares que permiten ejecutar DoS contra brokers MQTT es el paquete de software MQTT-malaria [25].
- Reconnaissance (Recon): Conjunto de técnicas que permiten al atacante identificar posibles víctimas y sus vulnerabilidades. Esta categoría incluye acciones como el escaneo de direcciones IP, puertos abiertos en los dispositivos activos, y el sistema operativo que usan, entre otros.
- Spoofing: Suplantación de la identidad de un usuario o un dispositivo mediante el envío de tramas o paquetes con direcciones MAC o IP falsas.
- Ataques de Intermediario (MiTM): El atacante consigue interceptar la comunicación entre dos dispositivos y como consecuencia es capaz de leer, modificar e inyectar datos en dicha comunicación. Ejecutar con éxito un MiTM requiere, en la mayoría de los escenarios, realizar previamente un ataque de spoofing, p. ej., un ataque de ARP spoofing.
- Injection: El atacante consigue introducir datos falsos en una comunicación ya establecida, por ejemplo, mediante el secuestro de una sesión (*session hijacking*).

B. Uso de la herramienta y análisis de los resultados

Una vez capturado el tráfico, el usuario puede cargar directamente archivos en formato PCAP en la herramienta. Esta analiza automáticamente las trazas, extrayendo estadísticas tanto a nivel de paquetes, como de flujos, ventanas de paquetes, y *nPrint*. Estas estadísticas son convertidas a formato CSV para ser utilizadas por modelos de inteligencia artificial.

Para el uso de la herramienta, se ejecuta la siguiente instrucción:

```
python3 miotta-npt.py archivo.pcap [--config
    config.yaml]
```

Donde *archivo.pcap* es la ruta del archivo PCAP a analizar, y *config* es el fichero de configuración en formato *.yaml* en el que se seleccionan los atributos que se quieren incluir en el archivo CSV o *nPrint* final; En el caso del archivo CSV, estos atributos consisten en:

- *size_of_window:* es el número de paquetes por ventana (por defecto: 10).
- *mode:* es el tipo de análisis que se desea ejecutar. Los valores disponibles son: paquetes (genera solo el CSV con todos los paquetes extraídos), ventana (estadísticas por ventana), flujos (estadísticas por flujo), combinada (estadísticas combinadas por ventana y flujo), y all (opción por defecto que ejecuta todos los modos anteriores).

Por otro lado, en el caso de *nPrint*, los atributos del archivo *.yaml* consisten en:

- *headers:* son las cabeceras de los protocolos que se quieren incluir en el fichero final.
- *masks:* son las cabeceras de las cuales se quiere eliminar información de localización para evitar el sobreaprendizaje del modelo.

Con la instrucción descrita anteriormente, y utilizando el archivo de configuración pertinente, los archivos PCAP pasados por entrada se convertirán a archivos CSV con las características indicadas para poder ser entrenados y evaluados por IDS basados en inteligencia artificial. En la Fig. 4 y Fig. 5, se muestran dos ejemplos de archivos

This work is licensed under a Creative Commons 4.0 International License (CC BY-NC-ND 4.0)

CSV obtenidos tras cargar un archivo PCAP en el que se ejecuta un ataque de denegación de servicio (DoS). El primer archivo CSV corresponde a algunos de los atributos de red extraídos a nivel de flujos y ventanas de paquetes, y el otro archivo corresponde a algunos de los atributos extraídos en formato *nPrint*.

Esta capacidad de generar diferentes tipos de salida hace que la herramienta sea también altamente configurable: permite al usuario testear múltiples configuraciones y combinaciones de atributos, facilitando así la experimentación con distintas representaciones del tráfico de red. En consecuencia, la herramienta se convierte en un recurso muy valioso tanto para investigadores como para profesionales que deseen optimizar el rendimiento de sus modelos de detección o análisis de tráfico en entornos de red realistas. La herramienta puede descargarse desde el siguiente repositorio de GitHub [11]: https://www.github.com/miotta2025/network-preprocessing-tool

Std_Length	Number	Magnite	Radius	Covariance	Var_Ratio
2,82843E+14	25	1,2E+16	40	1,06667E+16	75
2,88562E+16	25	1,1972E+16	4,0809E+15	1,11111E+15	75
2,82843E+14	25	1,1831E+16	40	1,06667E+16	75
2,82843E+14	25	1,2E+16	40	1,06667E+16	75
2,88562E+16	25	1,1972E+16	4,0809E+15	1,11111E+15	75
2,82843E+14	25	1,1831E+16	40	1,06667E+16	75
2,82843E+14	25	1,2E+16	40	1,06667E+16	75
2,88562E+16	25	1,1972E+16	4,0809E+15	1,11111E+15	75
2,82843E+14	25	1,1831E+16	40	1,06667E+16	75

Fig. 4: Captura de pantalla de algunos atributos extraídos por la herramienta a nivel de flujos y ventanas de paquetes.

ipv4_tl_12	ipv4_tl_13	ipv4_tl_14	ipv4_tl_15	ipv4_id_0	ipv4_id_1
1	0	0	0	0	0
1	0	0	0	0	0
1	1	0	1	0	0
1	1	0	1	0	0
1	0	0	0	0	0
1	0	0	0	0	0
1	0	0	0	0	0
1	1	0	1	0	0

Fig. 5: Captura de pantalla de algunos atributos extraídos por la herramienta en formato *nPrint*.

VI. CONCLUSIONES Y LÍNEAS FUTURAS

En este trabajo se ha presentado una herramienta de preprocesamiento de tráfico de red IoMT orientada a la generación configurable de *datasets* para sistemas de detección y prevención de intrusiones basados en inteligencia artificial. A diferencia de herramientas existentes, la propuesta destaca por su flexibilidad, permitiendo al usuario seleccionar el nivel de granularidad del análisis (paquete, flujo, ventana o combinado) y el conjunto específico de atributos a extraer, hasta un total de 103 características de tráfico de red. La herramienta también es compatible con el formato *nPrint*, facilitando la generación de representaciones binarias del tráfico para modelos de aprendizaje profundo. Además, la herramienta ha sido validada en un entorno experimental realista, el testbed MIoTTA-UPC, que replica el comportamiento de una habitación hospitalaria equipada con dispositivos médicos reales y simulados; demostrando la versatilidad de la herramienta en la extracción de datos tanto en escenarios normales como bajo distintos tipos de ciberataques. Los *datasets* generados permiten entrenar y evaluar algoritmos de detección de intrusiones con mayor eficacia, mejorando la identificación de amenazas en entornos médicos críticos. Asimismo, el diseño modular y abierto de la herramienta la convierte en una solución útil tanto para investigación como para aplicaciones prácticas en ciberseguridad médica, facilitando la generación de conjuntos de datos adaptados a múltiples necesidades experimentales y enfoques de modelado.

Como líneas futuras, se propone incorporar la generación de *datasets* con distribuciones específicas de clases, integrar un sistema automático de selección de atributos, y ofrecer visualizaciones estadísticas de los datos antes de su exportación.

AGRADECIMIENTOS

Esta publicación y sus resultados de investigación cuentan con el apoyo del programa predoctoral AGAUR-FI (2024 FI-1 00643) Ajuts Joan Oró y de la Cátedra de Ciberseguridad CARISMATICA, respaldados por la Secretaría de Universidades e Investigación del Departamento de Investigación y Universidades de la Generalitat de Cataluña, así como por el Fondo Social Europeo Plus y los fondos del Plan de Recuperación, Transformación y Resiliencia, financiados por la Unión Europea (Next Generation), bajo los auspicios del INCIBE. Además, queremos mostrar también nuestro agradecimiento por su contribución al desarrollo de la herramienta propuesta y del *testbed* a: Javier Marqués Martínez, Armand Serradell Torrens, Joel Otero Masplà y Oriol López Petit.

APPENDIX

En este apéndice, se presentan los 103 atributos que la herramienta de preprocesado puede extraer para el análisis de tráfico en los niveles de: paquete, flujo y ventana de paquetes. Asimismo, la Tabla II muestra los atributos de estos tres niveles y una descripción de cada uno de ellos. Además, una definición de como se calcula cada uno de los atributos puede encontrarse en la documentación presente en el GitHub [11].

REFERENCIAS

[1] D. Dimitrov, "Medical Internet of Things and big data in healthcare," *Healthcare Informatics Research*, vol. 22, p. 156, 07 2016.

[2] "ENISA THREAT LANDSCAPE: HEALTH SECTOR (january 2021 to march 2023)." [Online]. Available: https://www.enisa.europa.eu/publications/health-threat-landscape

[3] European Union Agency for Cybersecurity, R. Mattioli, and A. Malatras, *Foresight Cybersecurity Threats For 2030 - Update 2024: Extended report*. European Network and Information Security Agency, 2024.

[4] A. Heidari and M. A. J. Jamali, "Internet of Things intrusion detection systems: a comprehensive review and future directions," *Cluster Computing*, vol. 26, pp. 3753–3780, 12 2023.

[5] J. Doménech, I. V. Martin-Faus, S. Mhiri, and J. Pegueroles, "Ensuring patient safety in iomt: A systematic literature review of behavior-based intrusion detection systems," *Internet of Things*, vol. 28, p. 101420, 2024. [Online]. Available: https://www.sciencedirect.com/science/article/pii/S2542660524003615

[6] S. B. Weber, S. Stein, M. Pilgermann, and T. Schrader, "Attack detection for medical cyber-physical systems-a systematic literature review," *IEEE Access*, vol. 11, pp. 41 796–41 815, 2023.

[7] I. H. Sarker, "Machine learning: Algorithms, real-world applications and research directions," *SN Computer Science*, vol. 2, no. 3, p. 160, Mar 2021.

This work is licensed under a Creative Commons 4.0 International License (CC BY-NC-ND 4.0)

Tabla II: Atributos extraídos para el análisis de tráfico en los niveles de paquete, flujo y ventana de paquetes.

Paquete	**Descripción**	**Flujo**	**Descripción**	**Ventana paquetes**	**Descripción**
ip.src	Dirección IP origen	flow	Identificador flujo	Window	Número ventana
ip.dst	Dirección IP destino	Rate	Tasa total pqts/s	Header_Length	Longitud cabecera
ip.proto	Protocolo IP	Bytes	Total bytes flujo	TTL	TTL promedio
frame.len	Longitud total pqt	Min_Length	Longitud mínima pqts	syn_flag_number	Promedio flag SYN
tcp.flags	Flags TCP	Max_Length	Longitud máxima pqts	ack_flag_number	Promedio flag ACK
tcp.srcport	Puerto origen	Avg_Length	Longitud media pqts	HTTP	Presencia HTTP
tcp.dstport	Puerto destino	Std_Length	Desv. est. longitud	DNS	Presencia DNS
tcp.len	Longitud TCP	ack_count	Nº pqts con ACK	TCP	Tráfico TCP
udp.length	Longitud UDP	fin_count	Nº pqts con FIN	UDP	Tráfico UDP
ip.ttl	TTL del pqt	SRate	Tasa pqts forward	IAT	Tiempo entre pqts
tcp.hdr_len	Longitud header TCP	DRate	Tasa pqts backward	HTTPS	Presencia HTTPS
udp.srcport	Puerto UDP origen	Orig_Bytes	Bytes originador	Telnet	Presencia Telnet
udp.dstport	Puerto UDP destino	Resp_Bytes	Bytes respondedor	SMTP	Presencia SMTP
eth.type	Protocolo Ethernet	Orig_Pkts	Pqts originador	SSH	Presencia SSH
llc.control	Campo control LLC	Resp_Pkts	Pqts respondedor	IRC	Presencia IRC
frame.time	Timestamp pqt	Magnite	Magnitud dinámica	DHCP	Tráfico DHCP
ip.hdr_len	Longitud cabecera IP	Radius	Radio dinámico	ARP	Tráfico ARP
tcp.analysis.initial_rtt	RTT inicial	Covariance	Covarianza forw./backw.	ICMP	Tráfico ICMP
tcp.connection.fin	Fin conexión TCP	Var_Ratio	Ratio var. entre flujos	IGMP	Tráfico IGMP
tcp.connection.syn	Inicio conexión TCP	Weight	Peso dinámico flujo	IPV4	Tráfico IPv4
tcp.flags.cwr	Flag CWR	fwd_timestamps	Tiempos pqts forward	LLC	Tráfico LLC
tcp.flags.ecn	Flag ECN	bwd_timestamps	Tiempos pqts backward	tcp_analysis_initial_rtt	RTT inicial TCP
tcp.urgent_pointer	Puntero urgente TCP	Flow_Pkts_Payload	Payload total	tcp_connection_fin	Fin de conexión
ip.frag_offset	Offset fragmentación	Fwd_Pkts_Tot	Nº de pqts forward	tcp_connection_syn	Inicio conexión
eth.src_not_group	MAC no grupo	Bwd_Pkts_Tot	Nº de pqts backward	tcp_flags_cwr	Promedio flag CWR
–	–	Fwd_Data_Pkts_Tot	Nº de datos forward	tcp_flags_ecn	Promedio flag ECN
–	–	Bwd_Data_Pkts_Tot	Nº de datos backward	tcp_urgent_pointer	Puntero urgente TCP
–	–	Fwd_Pkts_Per_Sec	Tasa forward	ip_frag_offset	Offset fragmentación
–	–	Bwd_Pkts_Per_Sec	Tasa backward	eth_src_not_group	MAC no grupo
–	–	Fwd_Header_Size	Tamaño headers forw.	Protocol_type	Tipo protocolo
–	–	Bwd_Header_Size	Tamaño headers backw.	fin_flag_number	Promedio flag FIN
–	–	Fwd_Pkts_Payload	Payload forw.	rst_flag_number	Promedio flag RST
–	–	Bwd_Pkts_Payload	Payload back.	psh_flag_number	Promedio flag PSH
–	–	Fwd_IAT	Tiempo entre pqts forw.	ece_flag_number	Promedio flag ECE
–	–	Bwd_IAT	Tiempo entre pqts back.	cwr_flag_number	Promedio flag CWR
–	–	Flow_IAT	Tiempo entre pqts flujo	Tot_size	Tamaño medio pqts
–	–	Window	Número ventana flujo	–	–
–	–	syn_count	Nº pqts con SYN	–	–
–	–	rst_count	Nº pqts con RST	–	–
–	–	Number	Nº pqts flujo	–	–
–	–	flow_timestamps	Tiempo del flujo	–	–
–	–	Flow_Pkts_Per_Sec	Pqts/seg. en el flujo	–	–

[8] "CICFlowMeter," 2016, accessed on 29.05.2025. [Online]. Available: https://github.com/CanadianInstituteForCybersecurity/CICFlowMeter

[9] "IoT-Healthcare-Security-Dataset," 2021, accessed on 29.05.2025. [Online]. Available: https://github.com/imfaisalmalik/IoT-Healthcare-Security-Dataset

[10] "pcap2csv," 2023, accessed on 29.05.2025. [Online]. Available: {http://205.174.165.80/IOTDataset/CIC_IOT_Dataset2023/Dataset/Supplementary%20Materials/pcap2csv/}

[11] "Herramienta de preprocesamiento de tráfico iomt para generacón configurable de datasets," 2025, accessed on 11.06.2025. [Online]. Available: https://github.com/miotta2025/network-preprocessing-tool

[12] E. C. P. Neto, S. Dadkhah, R. Ferreira, A. Zohourian, R. Lu, and A. A. Ghorbani, "Ciciot2023: A real-time dataset and benchmark for large-scale attacks in iot environment," *Sensors*, vol. 23, no. 13, 2023. [Online]. Available: https://www.mdpi.com/1424-8220/23/13/5941

[13] S. Dadkhah, E. C. P. Neto, R. Ferreira, R. C. Molokwu, S. Sadeghi, and A. A. Ghorbani, "CICIoMT2024: A benchmark dataset for multi-protocol security assessment in IoMT," *Internet of Things*, vol. 28, p. 101351, 2024. [Online]. Available: https://www.sciencedirect.com/science/article/pii/S2542660524002920

[14] F. Hussain, S. G. Abbas, G. A. Shah, I. M. Pires, U. U. Fayyaz, F. Shahzad, N. M. Garcia, and E. Zdravevski, "A framework for malicious traffic detection in IoT healthcare environment," *Sensors*, vol. 21, no. 9, p. 3025, Apr. 2021.

[15] J. Areia, I. A. Bispo, L. Santos, and R. L. d. C. Costa, "Iomt-trafficdata: Dataset and tools for benchmarking intrusion detection in internet of medical things," *IEEE Access*, vol. 12, pp. 115 370–115 385, 2024.

[16] A. A. Hady, A. Ghubaish, T. Salman, D. Unal, and R. Jain, "Intrusion detection system for healthcare systems using medical and network data: A comparison study," *IEEE Access*, vol. 8, pp. 106 576–106 584, 2020.

[17] J. Holland, P. Schmitt, N. Feamster, and P. Mittal, "New directions in automated traffic analysis," in *Proceedings of the 2021 ACM SIGSAC Conference on Computer and Communications Security*, ser. CCS '21. New York, NY, USA: Association for Computing Machinery, 2021, p. 3366–3383. [Online]. Available: https://doi.org/10.1145/3460120.3484758

[18] "Wireshark," accessed on 11.06.2025. [Online]. Available: https://www.wireshark.org/

[19] J. Doménech, O. León, M. S. Siddiqui, and J. Pegueroles, "Evaluating and enhancing intrusion detection systems in iomt: The importance of domain-specific datasets," *Internet of Things*, vol. 32, p. 101631, 2025. [Online]. Available: https://www.sciencedirect.com/science/article/pii/S2542660525001453

[20] "Tshark", accessed on 11.06.2025. [Online]. Available: https://tshark.dev/

[21] A. Sarradell Torrens, "Implementation of a testbed for studying cyberattacks in iomt environments," *UPC, Escola Tècnica Superior d'Enginyeria de Telecomunicació de Barcelona, Departament d'Enginyeria Telemàtica*, 2025.

[22] J. Otero Masplà, "Deployment of a security testbed for iot," *UPC, Escola Tècnica Superior d'Enginyeria de Telecomunicació de Barcelona, Departament d'Enginyeria Telemàtica*, 2025.

[23] S. Ghazanfar, F. Hussain, A. U. Rehman, U. U. Fayyaz, F. Shahzad, and G. A. Shah, "Iot-flock: An open-source framework for iot traffic generation," in *2020 International Conference on Emerging Trends in Smart Technologies (ICETST)*, 2020, pp. 1–6.

[24] L. F. Maimó, A. H. Celdrán, Ángel L. Perales Gómez, F. J. G. Clemente, J. Weimer, and I. Lee, "Intelligent and dynamic ransomware spread detection and mitigation in integrated clinical environments," *Sensors (Switzerland)*, vol. 19, 3 2019.

[25] "Attacking MQTT systems with mosquittos (scalability and load testing utilities for MQTT environments)," accessed on 15.03.2025. [Online]. Available: https://github.com/etactica/mqtt-malaria

This work is licensed under a Creative Commons 4.0 International License (CC BY-NC-ND 4.0)